VBot Workplace

Trợ lý AI văn phòng trên Google Cloud cho 2.000 người dùng mỗi ngày

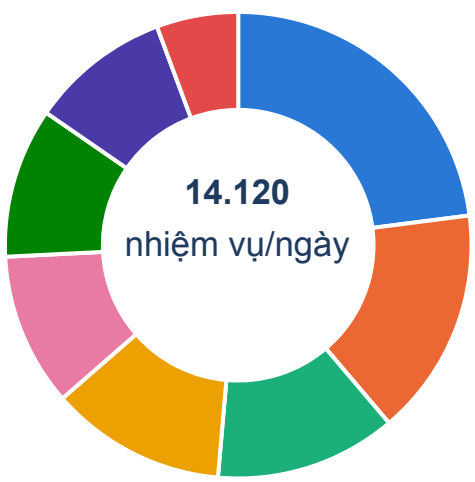
Tổng chi phí: 3.421,44 USD/tháng, tức 1,71 USD cho mỗi người dùng hoạt động (DAU)
Track 2 · Production Capstone · Nhóm G03

Thành viên
Lê Tuấn Anh · MSSV 2A202602952
Hồ Thái Hòa · MSSV 2A202602915
Nguyễn Đình Lâm Phúc · MSSV 2A202602986

1. Tải: 14.120 việc/ngày, 91% là việc nhẹ

Đề cho 2.000 người dùng mỗi ngày (DAU). Nhóm ước lượng từng việc của 8 phòng ban: số việc = khối lượng thật × tỉ lệ giao cho AI

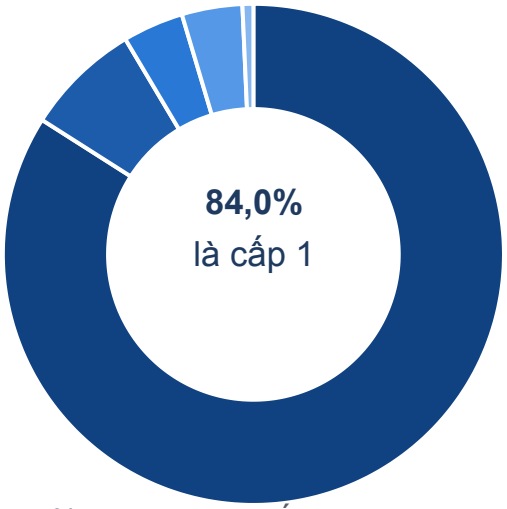
Ai tạo ra việc? Nhiệm vụ mỗi ngày theo phòng ban



Kinh doanh, CSKH (500)	3.242 · 23%
Quản lý dự án, vận hành (300)	2.237 · 16%
Kế toán (240)	1.777 · 13%
Nhân sự, HC, pháp chế (260)	1.723 · 12%
Marketing (200)	1.500 · 11%
IT (200)	1.469 · 10%
Mua hàng, SCM (200)	1.373 · 10%
Lãnh đạo, trợ lý (100)	800 · 6%

Kinh doanh, CSKH tạo nhiều việc nhất (23%) vì đông người nhất. Lãnh đạo, trợ lý dùng nhiều nhất tính theo đầu người: 8,00 nhiệm vụ/ngày (trung bình công ty: 7,06).

Việc gì? Nhiệm vụ chia theo 5 cấp



Cấp 1: Email, hỏi đáp	84,0%
Cấp 2: Viết tài liệu	7,4%
Cấp 3: Dữ liệu, code	3,9%
Cấp 4: Agent dự án	3,9%
Cấp 5: Thiết kế, sinh ảnh	0,7%

91% là việc nhẹ (cấp 1–2: email, hỏi đáp, tài liệu). Vì vậy một model rẻ đủ cho đa số (slide 4). Việc nặng (cấp 3–4: chạy code, agent nhiều bước) chỉ chiếm 7,8%.

Ví dụ: mỗi người gửi 9,9 email/ngày; nhóm giả định 30% số email nhờ AI soạn → 9,9 × 30% = 2,97 nhiệm vụ. Cộng mọi việc của mọi phòng ra 14.120 nhiệm vụ/ngày.

Chi tiết từng việc, từng phòng ban và nguồn số liệu: Phụ lục C và D.

1. Từ số việc ra token và tải lúc cao điểm

Hai con số quyết định chi phí: token mỗi tháng (tiền LLM) và lượt mỗi giây lúc cao điểm (số pod cần chạy)

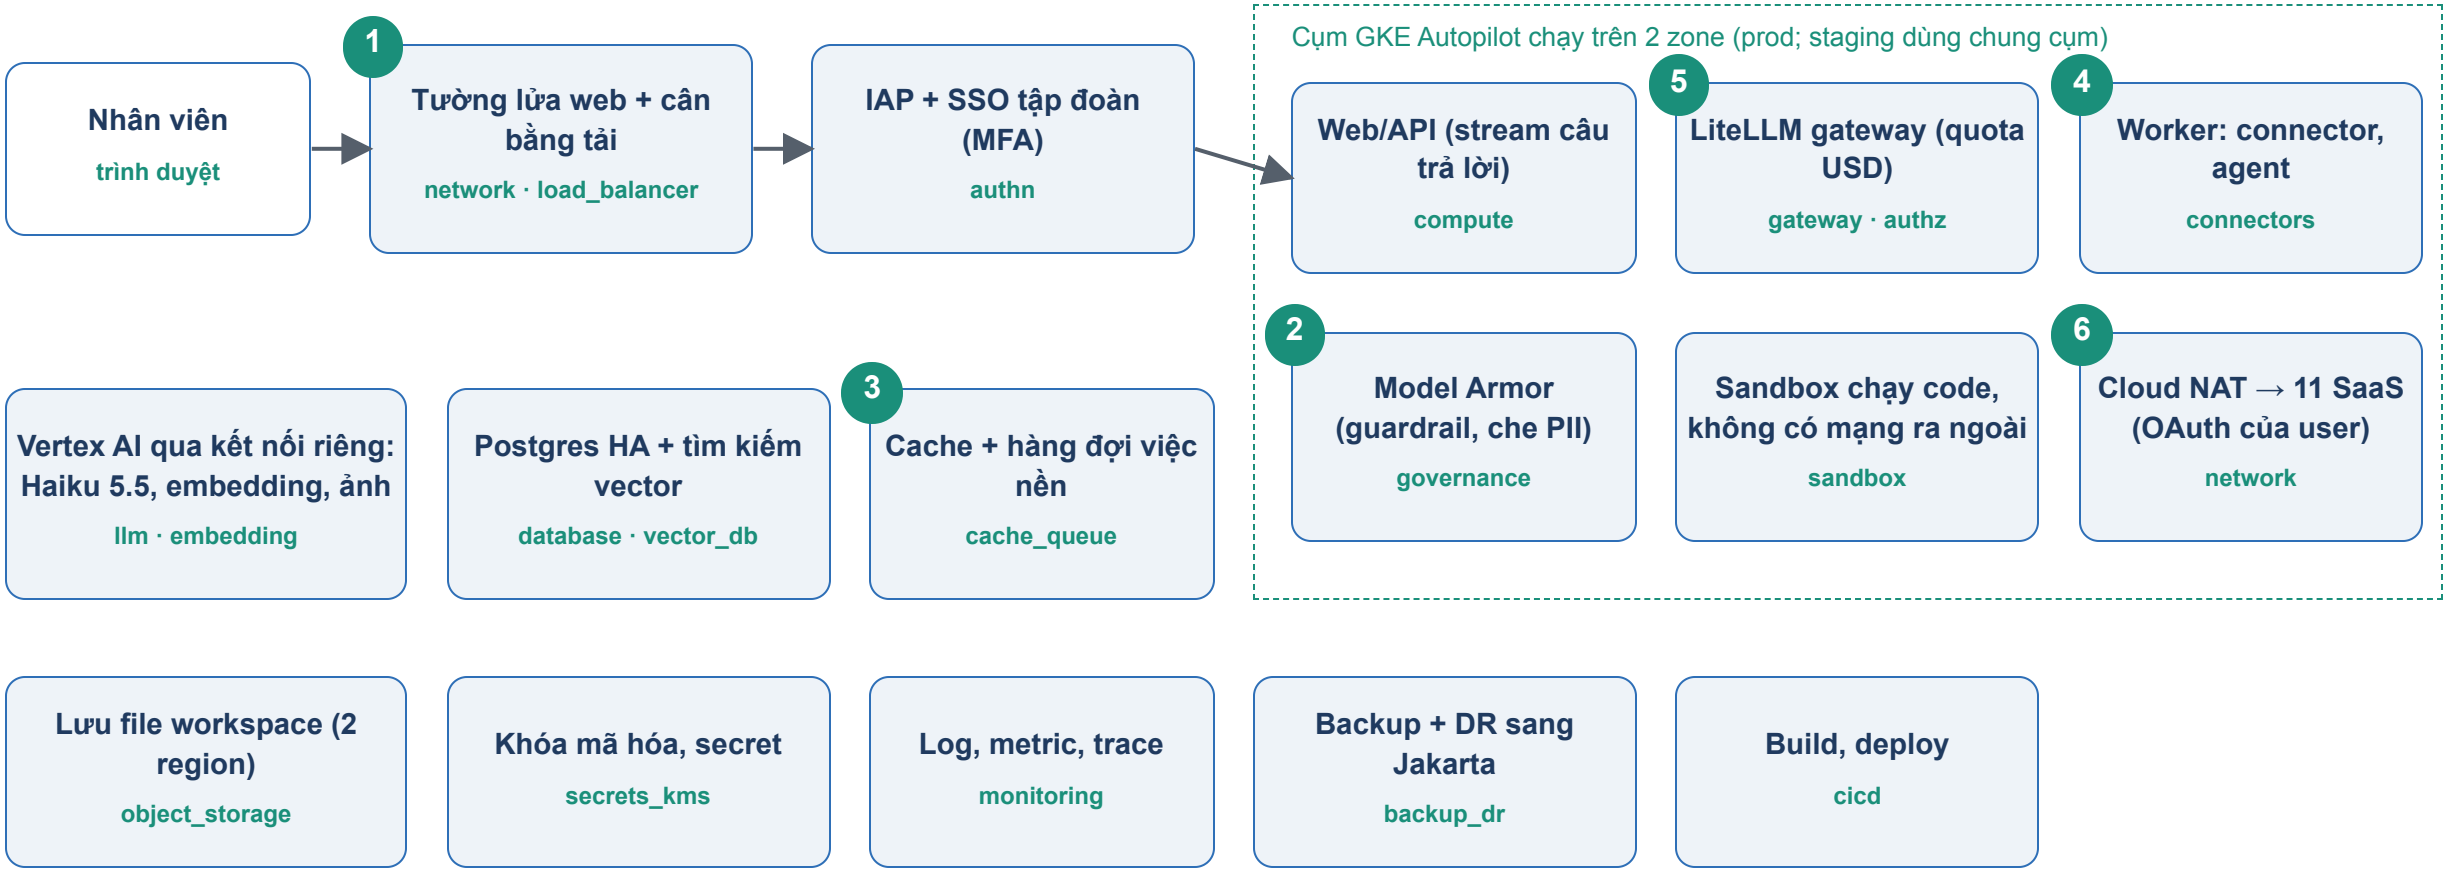
Chỉ số	Giá trị	Ảnh hưởng tới chi phí nào
Nhiệm vụ mỗi tháng	310.644 (14.120 × 22 ngày làm việc)	Mọi khoản tính theo lượt dùng
Lượt chat mỗi ngày	27.098 (mỗi nhiệm vụ khoảng 2 lượt)	Số lần gọi model
Lượt/giây lúc cao điểm	1,13 (giờ bận nhất = 15% lưu lượng cả ngày)	compute: số pod (284 USD/tháng)
Token mỗi tháng	12,19 tỉ vào + 0,79 tỉ ra; 61% token vào đọc từ cache	llm: 1.093 USD/tháng; token đọc từ cache rẻ hơn 10 lần
Lượt chạy code (sandbox)	140.800 lượt/tháng, tối đa 2 phút/lượt	sandbox: 315 USD/tháng
Ảnh sinh ra	4.312 ảnh/tháng (chỉ cấp 5)	Nằm trong llm: 147 USD/tháng
Dung lượng workspace	4 TB dùng thật (2.000 người × 2 GB)	object_storage: 83 USD/tháng

Cách đọc: số việc → số lượt chat → số token. Token nhân với giá model ra tiền LLM.

Số token mỗi lượt theo từng cấp lấy từ benchmark công khai (Azure On your data, DA-Code, MCP-Universe, MCPMark); chi tiết ở Phụ lục B.

2. Kiến trúc: một region GCP, không có điểm lỗi đơn

GCP Singapore vì rẻ nhất trong 3 cloud (3.421 USD/tháng; AWS 5.243, Azure 11.084). Số tròn là bước ở slide 3; chữ xanh là mã dòng trong báo giá



Mỗi thành phần có bản thứ hai ở zone khác (slide 9). Dữ liệu lưu tại Singapore; Vertex AI cam kết không lưu và không dùng dữ liệu để huấn luyện.

H1–H8 là 8 ràng buộc cứng của đề: H1 cloud · H2 phân quyền · H3 cô lập user · H4 AI governance · H5 data governance · H6 độ trễ · H7 HA, DR · H8 chất lượng, chi phí

3. Một request đi qua 3 cổng: SSO, guardrail, xác nhận

Ví dụ: "Tóm tắt thread email dự án X, rồi tạo 3 ticket Jira". Số bước khớp với số tròn trên sơ đồ slide 2

1. Đăng nhập

Request đi qua tường lửa web. IAP kiểm tra đăng nhập SSO và MFA của tập đoàn.

2. Kiểm tra đầu vào (cổng guardrail)

Model Armor quét tin nhắn để chặn prompt injection và lộ dữ liệu cá nhân. Mọi bước đều ghi audit.

3. Chạy nền

Việc nhiều bước (cấp 4) vào hàng đợi. User nhận "đang chạy nền" ngay, dưới 3 giây (H6).

4. Đọc email bằng quyền của chính user

Worker dùng OAuth token của user để tìm email. Nội dung email được đánh dấu "không tin cậy", không phải chỉ dẫn.

5. Gọi model

LiteLLM kiểm tra quota USD của user, rồi gọi Claude Haiku 5.5 trên Vertex AI. Agent đề xuất 3 ticket.

6. User xác nhận rồi mới ghi (cổng xác nhận)

User duyệt 3 ticket trên một màn hình. Worker tạo ticket, ghi audit, báo "xong" (tối đa 10 phút, H6).

4. Haiku 5.5 cho cả 5 cấp: 947 USD/tháng

Dùng API model trên Vertex AI, không tự host GPU. Chỉ nâng một cấp lên Sonnet 5.5 khi eval của cấp đó dưới 95%

Cấp	Model	Chế độ	Lượt/ngày	USD/tháng	Nếu eval < 95%: nâng lên
1 Email, hỏi đáp	Claude Haiku 5.5	tắt reasoning (cần nhanh)	20.507	386	Sonnet 5.5
2 Tài liệu	Claude Haiku 5.5	tắt reasoning (cần nhanh)	3.153	288	Sonnet 5.5
3 Dữ liệu, code	Claude Haiku 5.5	reasoning thấp	2.099	161	Sonnet 5.5: +2.939 USD
4 Agent dự án	Claude Haiku 5.5	reasoning thấp, chạy nền	1.042	105	Sonnet 5.5: +1.766 USD
5 Thiết kế	Haiku 5.5 + Gemini 3.1 Flash-Lite Image	1 ảnh/lượt	297	7 + 147 ảnh	—
Embedding	gemini-embedding-001	tìm kiếm tài liệu	—	20	—

Cách giữ chất lượng (eval gate, H8)

Bộ kiểm tra: 100 nhiệm vụ thật cho mỗi cấp, đã che dữ liệu cá nhân

Claude Opus 5.5 làm bài mẫu và chấm điểm; người chấm lại 10%

Đạt khi điểm Haiku ≥ 95% điểm Opus. Chạy lại mỗi lần đổi model hoặc prompt (525 USD/tháng)

Vì sao Haiku 5.5

Rẻ: 0,10 USD/1M token vào, 0,50 USD/1M token ra; token đọc từ cache chỉ 0,01

Điểm chất lượng cao nhất trong nhóm model cùng tầm giá (Artificial Analysis)

Dùng Opus cho mọi cấp sẽ tốn 36.380 USD/tháng, gấp 38 lần

Rủi ro: chưa có số đo độ trễ khi tắt reasoning → đo trong pilot

947 USD là tiền text. Cộng 147 USD tiền ảnh ≈ dòng llm 1.093 USD ở slide 11.

5. Mỗi lựa chọn đều rẻ hơn phương án thay thế

Chọn phương án rẻ nhất mà vẫn đạt đủ ràng buộc H1–H8. Đơn vị: USD/tháng. Cách tính từng con số: slide 5b

Quyết định	Chọn	Phương án so sánh	Lý do
Cloud chính	GCP: 3.421 (tổng)	AWS 5.243 · Azure 11.084	Rẻ nhất; chênh lệch chủ yếu ở guardrail
LLM gateway	LiteLLM tự chạy: 0 tiền license	Apigee ~1.595 · Azure APIM ~700	Duy nhất có quota USD theo từng user và phòng ban (H8)
Tìm kiếm vector	pgvector trong Postgres: 0 thêm	Vertex Vector Search ~84 · OpenSearch ~413	Dữ liệu nhỏ; lọc quyền bằng SQL ngay trong database
Cất token OAuth	Mã hóa bằng KMS, lưu trong Postgres: ~4	Secret Manager (12.000 secret) ~720	Vẫn mã hóa và có audit, rẻ hơn 180 lần
Sandbox	GKE Sandbox (gVisor): 315	Agent Engine 483 · AgentCore 509	Có sẵn trên cụm GKE; chặn mạng ra ngoài bằng NetworkPolicy
Guardrail	Chỉ quét text mới: 281	Quét toàn bộ token: 1.298	Mỗi đoạn text chỉ quét một lần, khi vào hệ thống
Connector	Gọi API bằng OAuth của user	Crawl toàn bộ dữ liệu vào index	SaaS tự áp quyền gốc; không cần tài khoản quyền rộng

Giá niêm yết tại Singapore, đọc ngày 16/10/2026. Lựa chọn model: slide 4.

5. Cách tính: đơn giá niêm yết × khối lượng tải

Mỗi con số ở slide 5a = đơn giá của dịch vụ × khối lượng ước lượng ở slide 1b. Đơn vị: USD/tháng; 1 tháng = 730 giờ

Quyết định	Phương án chọn: cách tính	Phương án so sánh: cách tính
Cloud chính	GCP 3.421 = tổng các dòng của báo giá (Phụ lục A)	AWS 5.243, Azure 11.084: cùng khối lượng, tính theo giá của AWS, Azure. Nếu bỏ dòng governance, 3 cloud chênh nhau dưới 16%. Chênh lệch nằm ở guardrail + che PII: GCP 281, AWS ~1.910, Azure ~7.534
LLM gateway	LiteLLM là phần mềm miễn phí. 2 pod chạy trong cụm GKE, tiền máy đã nằm trong dòng compute	Apigee: môi trường Intermediate 1.460 + phí theo lượt gọi model (100 USD/1 triệu lượt) ≈ 1.595. Azure APIM Standard v2: 0,96 USD/giờ × 730 giờ ≈ 700
Tìm kiếm vector	pgvector là extension của Postgres, chạy trong database đã có (467 USD), chỉ tốn thêm ít dung lượng	Vertex Vector Search: tối thiểu 1 máy e2-standard-2 chạy 24/7 ≈ 84. OpenSearch: tối thiểu 2 OCU × 0,283 USD/giờ × 730 giờ ≈ 413
Cất token OAuth	3 khóa KMS × 0,06 + 760.000 lần mã hóa/giải mã × 0,03 USD/10.000 lần + 20 secret hệ thống ≈ 4	Mỗi token một secret: 2.000 user × 6 connector = 12.000 secret × 0,06 USD ≈ 720
Sandbox	140.800 lượt × 2 phút = 4.693 vCPU-giờ × 0,0549 + 9.386 GB-giờ × 0,0061 ≈ 315	Cùng số giờ, theo giá Agent Engine (0,085 USD/vCPU-giờ) ≈ 483; AgentCore (0,0895 USD/vCPU-giờ) ≈ 509
Guardrail	Chỉ quét text mới: 2,81 tỉ token/tháng × 0,10 USD/1 triệu token ≈ 281	Quét toàn bộ token: (12,19 + 0,79) tỉ token × 0,10 USD/1 triệu token ≈ 1.298

Giá niêm yết tại Singapore, đọc ngày 16/10/2026, chưa VAT. Sandbox tính theo trần 2 phút/lượt nên là cận trên.

Đơn giá và khối lượng của từng dòng: cột Ghi chú và Bằng chứng trong G03_baogia.xlsx.

6. Agent chỉ thấy những gì user được thấy (H2)

Agent dùng 11 connector (Google, Microsoft, Atlassian, Notion) bằng quyền OAuth của chính user

Đăng nhập

SSO bằng tài khoản tập đoàn có sẵn, bắt buộc MFA

Phân quyền chức năng theo nhóm (ví dụ: chỉ IT dùng sandbox hạng lớn)

Agent mượn quyền của user (OAuth)

Mỗi user tự cho phép từng SaaS; mặc định chỉ quyền đọc

Quyền ghi (gửi email, tạo ticket) chỉ xin khi cần

Không dùng tài khoản dịch vụ có quyền rộng

Token được cất an toàn

Token OAuth được mã hóa bằng khóa trong Cloud KMS, lưu trong Postgres

Chỉ worker được giải mã, và chỉ cho đúng user của request. Mỗi lần giải mã đều ghi audit

Tài liệu giữ quyền gốc

Mail, lịch, Jira: agent gọi search API của SaaS bằng token của user, nên SaaS tự lọc quyền

Tài liệu chung đã index: mỗi đoạn ghi nhóm được xem; mọi truy vấn lọc theo nhóm của user

API của 11 SaaS không tính phí theo lượt; tập đoàn đã có license SaaS. Rate limit của SaaS: slide 12.

7. File của user A không lộ sang user B (H3)

"Agent của A có đọc được file của B không?" Không, vì có 4 lớp chặn:

Lớp	Cách chặn
Lưu trữ	Mỗi user một thư mục riêng; chỉ app có quyền vào bucket
Database	Postgres tự lọc dòng theo người sở hữu (Row-Level Security)
Tìm kiếm	Mọi truy vấn bắt buộc lọc theo người sở hữu hoặc nhóm
Connector	Dùng OAuth của chính user, nên không thấy dữ liệu người khác

Sandbox: code của agent chạy trong hộp kín

gVisor ngăn code chạm trực tiếp vào kernel của máy chủ

Không có mạng ra ngoài: không internet, không mạng nội bộ

Chỉ thấy thư mục workspace của đúng user đó

Tối đa 2 phút (hạng lớn 10 phút); chạy xong hoặc hết giờ thì hủy pod

Code cố thoát ra máy chủ?

Bị gVisor chặn. Pod không có quyền đặc biệt và không gọi được API của cloud

8. Lệnh ẩn trong email bị chặn ở 3 chỗ (H4, H5)

"Một email chứa lệnh ẩn: gửi toàn bộ hợp đồng ra ngoài." Lệnh này không chạy được, vì:

1. Guardrail quét nội dung

Model Armor quét tin nhắn mới, nội dung từ connector và câu trả lời cuối (281 USD/tháng)

2. Nội dung email chỉ là dữ liệu

Nội dung từ connector được đánh dấu "không tin cậy". Chỉ yêu cầu của user mới kích hoạt được hành động ghi

3. User xác nhận trước khi ghi

Gửi ra ngoài, xóa, chia sẻ quyền: xác nhận từng việc. Ticket, email nháp: duyệt một lần cho cả nhóm

Thêm nữa: sandbox không có mạng ra ngoài, nên code cũng không gửi được dữ liệu

Bảo vệ dữ liệu

Mã hóa khi lưu và khi truyền

Che dữ liệu cá nhân (PII) trước khi gửi cho model

Vertex AI không lưu và không dùng dữ liệu để huấn luyện

Audit log 12 tháng: ai, lúc nào, dùng tool nào, xác nhận hành động gì

Eval gate

Đổi model hoặc prompt phải chạy lại bộ kiểm tra; dưới 95% thì không deploy (525 USD/tháng)

Dòng governance ở slide 11 = 281 USD guardrail + 525 USD eval = 806 USD/tháng. Thời hạn lưu khác: chat 12 tháng, file tạm 30 ngày, prompt log 30 ngày (đã che PII).

9. Mất 1 zone: tự chuyển trong 1–2 phút (H7)

Đề yêu cầu: chạy 99,5% giờ hành chính, khôi phục trong 4 giờ (RTO), mất tối đa 1 giờ dữ liệu (RPO)

Thành phần	Chạy liên tục (HA)	Backup, khôi phục (DR)
Tường lửa, cân bằng tải	Managed, đa zone	—
Cụm GKE	Mỗi pod 2 bản ở 2 zone	Dựng lại bằng Terraform
LiteLLM, web, worker	2 bản, 2 zone	Image lưu trong Artifact Registry
Postgres (Cloud SQL)	Bản dự phòng ở zone khác, tự chuyển	Backup hằng ngày, khôi phục về thời điểm bất kỳ; bản sao ở Jakarta
Cache	Bản chính + bản phụ	Không cần (chỉ dữ liệu tạm)
File workspace	Đa zone	Lưu ở 2 region
Vertex AI	Endpoint global	Model dự phòng qua LiteLLM

Khi mất 1 zone lúc 10:00

Cân bằng tải chuyển traffic sang zone còn lại; GKE tạo thêm pod

Postgres tự chuyển sang bản dự phòng trong vài chục giây đến 1–2 phút

Vài request lỗi, user gửi lại được; dữ liệu đã lưu không mất

Khi mất cả region Singapore

Dựng lại ở Jakarta bằng Terraform và backup đã sao chép: ≤ 4 giờ, mất ≤ 1 giờ dữ liệu

Diễn tập và chi phí

Thử khôi phục DB mỗi quý, dựng region DR mỗi 6 tháng. backup_dr: 164 USD/tháng

10. Mỗi user có quota USD; vượt thì hạ cấp (H8)

LiteLLM ghi chi phí của từng user và phòng ban, nên mỗi tháng biết ai tiêu bao nhiêu và chặn được khi vượt

Cảnh báo chính

Chậm: p95 thời gian tới token đầu tiên > 3 giây trong 10 phút

Agent chạy quá 10 phút; tỉ lệ lỗi > 2%

Cache hit < 50%, tức chi phí LLM sắp tăng

Chi tiêu trong ngày vượt dự báo 20%

Dashboard

Token và USD theo user, phòng ban, model, cấp

Số lần guardrail chặn, số hành động ghi bị user từ chối

Mức dùng quota tháng	Hành động
80%	Cảnh báo user; báo trưởng phòng nếu là quota phòng
100%	Hạ cấp: cấp 1–2 chỉ dùng model rẻ nhất; khóa cấp 4–5
120%	Chặn đến đầu tháng sau, trừ khi trưởng phòng duyệt
90% ngân sách hệ thống	Cảnh báo nhóm FinOps và ban IT

Quota đặt bao nhiêu?

Chi phí theo lượt dùng (LLM + guardrail + sandbox) ≈ 1,11 USD/user/tháng

Quota mặc định: 3 USD/user/tháng, gần 3 lần mức trung bình, đủ cho người dùng nhiều

Báo cáo hằng tháng theo phòng ban

11. Chi phí: LLM 32%, governance 24%

Tổng 3.421,44 USD/tháng, tức 1,71 USD/DAU. Bảng dưới giải thích vì sao mỗi khoản ra con số này

Khoản	USD/tháng	%	Cách tính	Vì sao lớn hay nhỏ
llm	1.093	32%	Lượt × số lần gọi model × token × giá. Cấp 1: 386 · cấp 2: 288 · cấp 3: 161 · cấp 4: 105 · cấp 5: 7 + ảnh 147 (4.312 ảnh × 0,034)	Lớn nhất vì tăng theo lượt dùng. Vẫn nhỏ nhờ Haiku rẻ (0,10 USD/1M token vào) và 61% token vào đọc từ cache với giá 0,01
governance	806	24%	Guardrail: 2,81 tỉ token × 0,10 USD/1M = 281. Eval gate: 4 lần/tháng × 5 cấp × 100 nhiệm vụ = 525	Eval đắt hơn guardrail vì Opus 5.5 vừa làm bài mẫu vừa chấm điểm
database	467	14%	Postgres HA 2 vCPU, 13 GB × 730 giờ = 355 · SSD 150 GB = 71 · database staging = 41	Chạy 24/7, có bản dự phòng ở zone khác. Chứa luôn vector và token, nên không cần dịch vụ riêng
sandbox	315	9%	140.800 lượt × 2 phút = 4.693 vCPU-giờ × 0,0549 + 9.386 GB-giờ × 0,0061	Là cận trên: thời gian chạy thật chưa đo, nên mỗi lượt tính đủ 2 phút tối đa
compute	284	8%	Phí cụm GKE 0,10 USD/giờ × 730 = 73 · 3 loại pod (web, LiteLLM, worker): 2.970 vCPU-giờ + 7.920 GB-giờ = 211	Nhỏ vì giờ hành chính chạy 2 pod mỗi loại, ngoài giờ chỉ 1 pod
9 khoản còn lại	457	13%	backup_dr 164 · object_storage 83 · network 64 · cache_queue 56 · load_balancer 29 · …	Hạ tầng gọn: 1 cụm GKE, 1 region

Không gồm chi phí nhân sự vận hành (theo hướng dẫn của coach). Đơn giá và bằng chứng từng dòng: Phụ lục A và G03_baogia.xlsx.

11. Đòn bẩy: mỗi lựa chọn tiết kiệm bao nhiêu

Tiết kiệm = chi phí của phương án thay thế − chi phí của phương án nhóm chọn. Đơn vị: USD/tháng

Đòn bẩy	Tiết kiệm	Cách tính
Haiku cho cả 5 cấp, thay Sonnet ở cấp 3–4	4.705	Sonnet cho cấp 3 tốn thêm 2.939, cấp 4 tốn thêm 1.766. Eval gate kiểm tra Haiku vẫn đạt ≥ 95% điểm Opus
LiteLLM thay Apigee	~1.595	Apigee: môi trường Intermediate 1.460 + phí theo lượt gọi. LiteLLM miễn phí, chạy trong compute
Guardrail chỉ quét text mới	1.018	Quét toàn bộ 12,98 tỉ token = 1.298 − quét 2,81 tỉ token mới = 281
Cất token bằng KMS trong Postgres	~716	12.000 secret × 0,06 = 720 − KMS ≈ 4
Prompt caching	670	7,44 tỉ token vào đọc từ cache × (0,10 − 0,01) USD/1M token
Ngoài giờ chỉ chạy 1 pod mỗi loại	109	510 giờ ngoài giờ × 3 loại pod: 1.530 vCPU-giờ × 0,0549 + 4.080 GB-giờ × 0,0061
pgvector trong Postgres	~84	Vertex Vector Search cần tối thiểu 1 máy chạy 24/7
Staging dùng chung cụm GKE	73	Cụm riêng mất thêm phí quản lý: 0,10 USD/giờ × 730 giờ

Mỗi dòng so với một phương án thay thế riêng, nên không cộng dồn các dòng.

Chưa tính phí ghi cache của Claude (ước tính vài %). Không mua gói support. Không có dòng dự phòng.

12. Rủi ro lớn nhất: Haiku không đạt eval ở cấp 3–4

Khi đó chi phí lên 8.126 USD/tháng. Nhóm đã tính sẵn; LiteLLM đổi model bằng 1 dòng cấu hình

Kịch bản	USD/tháng	USD/DAU
Cơ sở (2.000 DAU)	3.421	1,71
DAU gấp đôi = 4.000	5.426	1,36
Giá token +30%	3.863	1,93
Giá token −50%	2.685	1,34
Cấp 3–4 phải nâng lên Sonnet 5.5	8.126	4,06
Workspace đầy 20 TB	+ ~704	—

Khi DAU gấp đôi, USD/DAU giảm

Tăng theo lượt dùng: LLM, guardrail, sandbox, lưu trữ, log

Gần như cố định: cụm GKE, database, cache, cân bằng tải

Chỉ xét tự host GPU khi tiền token vượt chi phí chạy ≥ 2 GPU 24/7 cộng vận hành

Các rủi ro khác và cách xử lý

Token thực tế khác giả định: nhóm dùng 13 tỉ token/tháng, khoảng có thể là 4,6–42,8 tỉ → đo trong pilot 2–4 tuần

Luật bảo vệ dữ liệu cá nhân (Nghị định 13/2023): Vertex AI dùng endpoint global → dữ liệu nhạy cảm dùng model chạy tại Singapore

LiteLLM là open source, không có SLA → đội vận hành trực, cố định phiên bản, test trên staging

Rate limit Jira/Confluence dùng chung cho cả app (65.000 điểm/giờ) → hàng đợi và thử lại

Google dự kiến tính phí API Workspace từ cuối 2026 (chưa công bố giá)

Phụ lục A. Báo giá theo component (USD/tháng)

Sắp xếp từ cao tới thấp. Chi tiết từng dòng (đơn giá × số lượng, kèm bằng chứng) nằm trong G03_baogia.xlsx

Component	USD/tháng	%
llm	1.093,34	32,0%
governance	805,98	23,6%
database	466,71	13,6%
sandbox	314,64	9,2%
compute	284,15	8,3%
backup_dr	164,40	4,8%
object_storage	82,80	2,4%
network	64,26	1,9%
cache_queue	55,75	1,6%
load_balancer	29,44	0,9%

Component	USD/tháng	%
monitoring	22,51	0,7%
embedding	19,50	0,6%
cicd	14,00	0,4%
secrets_kms	3,96	0,1%
authn	0,00	0,0%
authz	0,00	0,0%
connectors	0,00	0,0%
gateway	0,00	0,0%
ops_labor	0,00	0,0%
vector_db	0,00	0,0%
TOTAL	3.421,44	100%

Phụ lục B. Nguồn số liệu

Giá: trang giá chính thức của Google Cloud (GKE, Vertex AI, Cloud SQL, Cloud Storage, Memorystore, Cloud Tasks, KMS, Secret Manager, Observability, Security Command Center, Cloud Armor, VPC network, Cloud Build, Artifact Registry, IAP), đọc ngày 16/10/2026

So sánh với AWS và Azure: AWS Price List API, Azure Retail Prices API (region ap-southeast-1, southeastasia)

Tải: Microsoft WorkLab 2025; Dillon et al., Shifting Work Patterns with Generative AI (2025); Radicati 2015; APQC; Brynjolfsson et al. NBER 31161; Graphite Research; Liang et al. 2025; UK DBT Copilot evaluation 2025

Token mỗi lượt chat (số lần gọi model × token vào / token ra): cấp 1: 2 × 5,5k / 250 · cấp 2: 2 × 18k / 2,5k · cấp 3: 3,5 × 12k / 1k · cấp 4: 8 × 15k / 300 · cấp 5: 1,5 × 4k / 600 + 1 ảnh

Nguồn token: Azure OpenAI On your data defaults; Vertex RAG Engine; DA-Code; DABstep; MCP-Universe; MCPMark; OpenRouter State of AI 2025; Azure LLM inference trace 2024

Chất lượng và tốc độ model: Artificial Analysis Intelligence Index v4.3.2

Lương: ITviec Vietnam IT Salary & Recruitment Market 2024–2025; tỉ giá Vietcombank ngày 16/10/2026

Connector: Microsoft Graph throttling, Atlassian rate limiting, Notion request limits, Google Workspace API limits

Chi tiết nghiên cứu: thư mục research/ (usage-benchmarks, task-volume-by-role, token-per-task, r1, r2, r3, r5-r9, r8-r6) và cost_model.py

Phụ lục C. Việc chung của mọi nhân viên: 6,26 nhiệm vụ/ngày

Ai cũng làm 5 việc này. Số nhiệm vụ = khối lượng việc thật mỗi ngày × tỉ lệ giao cho AI

Việc	Cấp	Khối lượng thật/người/ngày	Tỉ lệ giao AI	Nhiệm vụ/người/ngày	Căn cứ
Soạn, trả lời email	1	9,9 email gửi	30%	2,97	Trung bình nhân của 2,9 (Microsoft RCT 2025) và 34 (Radicati). 30% cao hơn mức 10–24% của Liang 2025 vì công ty triển khai chính thức
Tóm tắt, phân loại email	1	32,2 email đọc	5%	1,61	Microsoft RCT 2025: 160,8 email đọc/tuần. Tỉ lệ 5%: giả định của nhóm
Hỏi đáp tài liệu nội bộ	1	4,0 lần tra cứu	30%	1,20	Mỗi người mất 1,6–2 giờ/ngày tìm thông tin (McKinsey, Atlassian). 4 lần và 30%: giả định của nhóm
Biên bản họp → DOCX	2	2,0 cuộc họp	20%	0,40	Microsoft RCT 2025: 9,9 cuộc họp/tuần. Tỉ lệ 20%: giả định của nhóm
Báo cáo, đề xuất → DOCX/PPTX	2	0,15 tài liệu	50%	0,08	Microsoft RCT 2025: 0,76 tài liệu Word hoàn thành/tuần. Tỉ lệ 50%: giả định của nhóm
Cộng				6,26	

Đọc bảng thế nào

Ví dụ dòng đầu: mỗi người gửi khoảng 9,9 email/ngày. Nhóm giả định 30% số email đó nhờ AI soạn, nên 9,9 × 30% = 2,97 nhiệm vụ.

Khối lượng việc lấy từ số đo thật (telemetry, khảo sát). Tỉ lệ giao AI phần lớn là giả định của nhóm; nhóm sẽ đo lại trong pilot 2–4 tuần.

Phụ lục D. Việc riêng của từng phòng ban

Mỗi người = 6,26 nhiệm vụ việc chung + việc riêng của phòng. Cả phòng = số người × nhiệm vụ mỗi người

Phòng ban (số người)	Phòng làm gì	Việc riêng giao AI (nhiệm vụ/người/ngày)	Mỗi người/ngày	Cả phòng/ngày
Kinh doanh, CSKH (500)	Bán hàng, chăm sóc khách hàng	Phân tích doanh số trên Excel 0,10 · agent chuẩn bị gặp khách 0,10 · ảnh cho báo giá 0,03	6,26 + 0,23 = 6,49	500 × 6,49 = 3.242
Quản lý dự án, vận hành (300)	Điều phối dự án, vận hành hằng ngày	Agent tạo ticket Jira, trang Confluence 0,90 · phân tích dữ liệu vận hành 0,12 · báo cáo tuần 0,10 · sơ đồ quy trình 0,08	6,26 + 1,20 = 7,46	300 × 7,46 = 2.237
Kế toán (240)	Sổ sách, thanh toán, báo cáo tài chính	Phân tích bảng tính tài chính, đối soát 0,80 · tìm hóa đơn bất thường 0,30 · checklist khóa sổ 0,05	6,26 + 1,15 = 7,41	240 × 7,41 = 1.777
Nhân sự, HC, pháp chế (260)	Tuyển dụng, chính sách, hợp đồng	Rà soát hợp đồng 0,15 · soạn mô tả công việc, chính sách 0,09 · tổng hợp chấm công 0,08 · đặt lịch phỏng vấn 0,05	6,26 + 0,37 = 6,63	260 × 6,63 = 1.723
Marketing (200)	Nội dung, chiến dịch, hình ảnh	Viết bài đăng, thông cáo 0,80 · ảnh, banner 0,25 · số liệu chiến dịch 0,12 · cập nhật kế hoạch 0,08	6,26 + 1,24 = 7,50	200 × 7,50 = 1.500
IT (200)	Phát triển phần mềm, hạ tầng, hỗ trợ	Tra cứu, phân loại ticket hỗ trợ 0,60 · agent cập nhật Jira, runbook 0,20 · viết code 0,16 · review code 0,08 · sơ đồ 0,05	6,26 + 1,09 = 7,35	200 × 7,35 = 1.469
Mua hàng, SCM (200)	Nhà cung cấp, đặt hàng, giao hàng	So sánh báo giá nhà cung cấp 0,56 · agent cập nhật lịch giao hàng 0,05	6,26 + 0,61 = 6,87	200 × 6,87 = 1.373
Lãnh đạo, trợ lý (100)	Ra quyết định, họp nhiều	Họp 4,6 cuộc/ngày nên biên bản họp là 0,92 thay vì 0,40 · agent chuẩn bị briefing 0,92 · sắp lịch 0,20 · slide 0,10	6,26 + 1,74 = 8,00	100 × 8,00 = 800
Toàn công ty (2.000)			7,06 (trung bình)	14.120

Số đã làm tròn 2 chữ số. Nguồn khối lượng việc riêng: APQC (hóa đơn, đơn mua hàng), Graphite (code), MetricNet (ticket IT), HBR 2017 (giờ họp của lãnh đạo); còn lại là giả định của nhóm.